Imersão em IA

IA em Escala

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

O Fim da Máquina Única

- LLMs explodiram em parâmetros (Bilhões).
- VRAM de uma GPU não comporta o modelo.
- Treinar um Llama-3 levaria anos em um PC.
- Escalar não é luxo, é sobrevivência.
- O hardware local tornou-se o gargalo da IA.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Latência vs. Throughput

- **Latência:** Tempo entre a pergunta e a resposta.
- Importante para o app CAIXA (UX/Cliente).
- **Throughput:** Vazão total do sistema (TPS).
- Processar milhões de propostas de crédito/dia.
- **Foco:** Eficiência de custo e ROI da infra.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Latência vs. Throughput

- **Latência:** Tempo entre a pergunta e a resposta.
- Importante para o app CAIXA (UX/Cliente).
- **Throughput:** Vazão total do sistema (TPS).
- Processar milhões de propostas de crédito/dia.
- **Foco:** Eficiência de custo e ROI da infra.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Missão Lab 01a: A Ilusão da Velocidade

Desafio: Simulação de Risco de Crédito (Monte Carlo)

- **Cenário 1:** Execução Serial (CPU).
- **Cenário 2:** Paralelismo Real (Multi-CPU).
- **Cenário 3:** O Salto Tecnológico (GPU PyTorch).
- **Objetivo:** Medir o **Speedup** e a **Eficiência**.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Teorema CAP (A Lei do Impossível)

- Escolha 2 pilares, perca 1.
- **Consistency:** Todos veem o mesmo dado.
- **Availability:** O sistema nunca para.
- **Partition Tolerance:** Resiste a falhas de rede.
- IA Bancária vive nesse trade-off.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Teorema CAP (A Lei do Impossível)

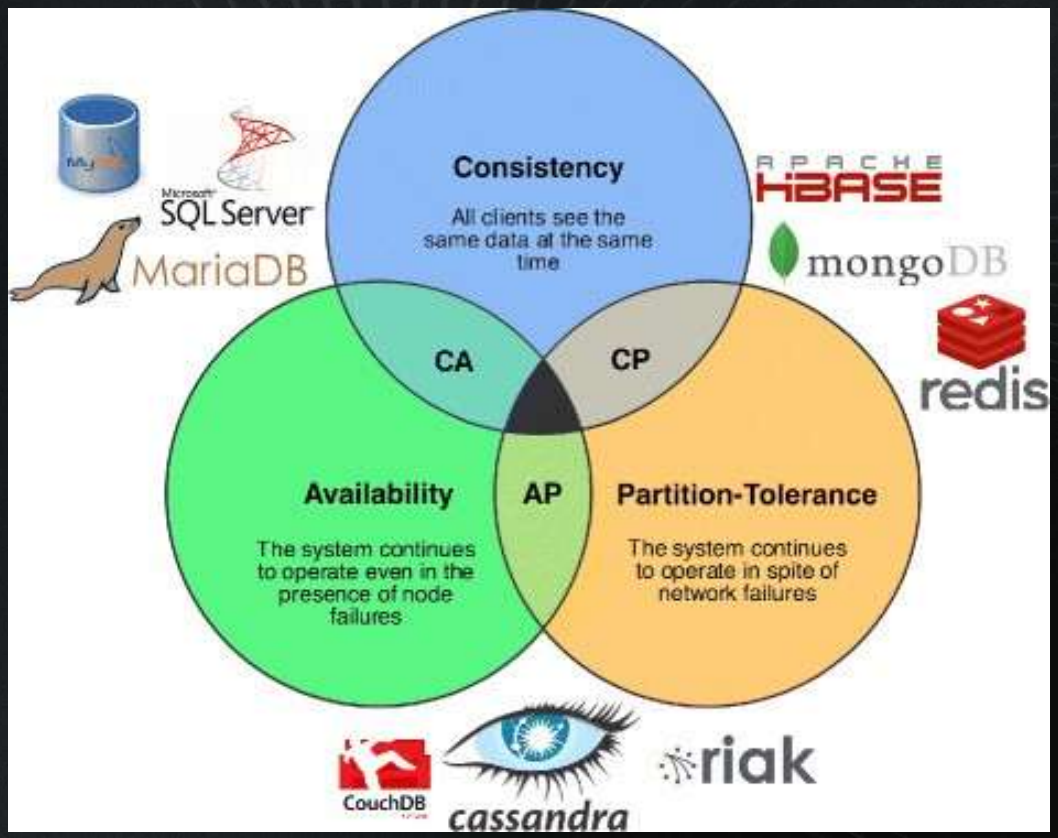

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

CAP na Prática Bancária

- **Consistência:** Importante para saldos bancários.
- **Disponibilidade:** Importante para Pix.
- **Partição:** Obrigatória para clusters SP/BSB.
- Distribuir o dado introduz latência de sincronia.
- Não existe almoço grátis na escala.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Estratégias de Paralelismo

- **Data Parallel:** Replicar o modelo, fatiar o dado.
  - Padrão para treinamento massivo.
- **Model Parallel (Sharding):** Cortar o modelo.
  - Única saída para modelos gigantes (LLMs).
  - Exige infra de rede ultra-rápida (NVLink).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Missão Lab 01b: O Custo da Conversa

Desafio: Sistema de Processamento PIX

- **Variáveis:** Latência de Rede e Taxa de Falha.
- **Teoria das Filas:** O "Joelho da Curva".
- **Objetivo:** Encontrar o **Ponto de Saturação**.
- Quando adicionar máquinas deixa tudo mais lento?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Conclusão do Dia

- Escalar exige coordenação (Master/Worker).
- Paralelismo local (GPU) tem teto de memória.
- Rede é o novo gargalo da infraestrutura.
- **Próxima Aula: Apache Spark & Databricks.**
- Vamos sair de uma máquina para um Cluster.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 02

De Scripts para Serviços

- Transformando o script em uma API (**FastAPI**).
- Portabilidade total com **Docker**.
- **Desafio:** Como levar esse modelo para o OpenShift da CAIXA?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS