Imersão em IA

O Motor do Big Data Apache Spark

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **A Evolução do Fogo:** De Hadoop (Disco) para Spark (RAM).
- **Arquitetura de Guerra:** Driver vs. Workers.
- **O Segredo da Eficiência:** Lazy Evaluation e DAGs.
- **Lab 02a:** Primeiro Contato com o Databricks Free Edition.
- **Shuffling:** O "Trânsito" que Mata a Performance.
- **IA Distribuída:** Machine Learning com Spark MLlib.
- **Lab 02b:** Treinando Modelos de Fraude em Escala.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Por que o Spark substituiu o Hadoop?

A Revolução da Memória (RAM)

- **Hadoop (MapReduce):** Gravava dados no Disco a cada passo.
- **Spark:** Mantém tudo na RAM (100x mais rápido ou mais).
- **Unificação:** Único motor para SQL, Streaming, Gráficos e IA.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

A Anatomia do Cluster (Driver vs. Worker)

Quem manda e quem faz no Spark?

- **Driver:** Analisa o código, cria o plano e distribui as tarefas.
- **Workers:** Executam o código e processam as partições de dados.
- **Cluster Manager:** Aloca máquinas (K8s e Databricks).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

A Anatomia do Cluster (Driver vs. Worker)

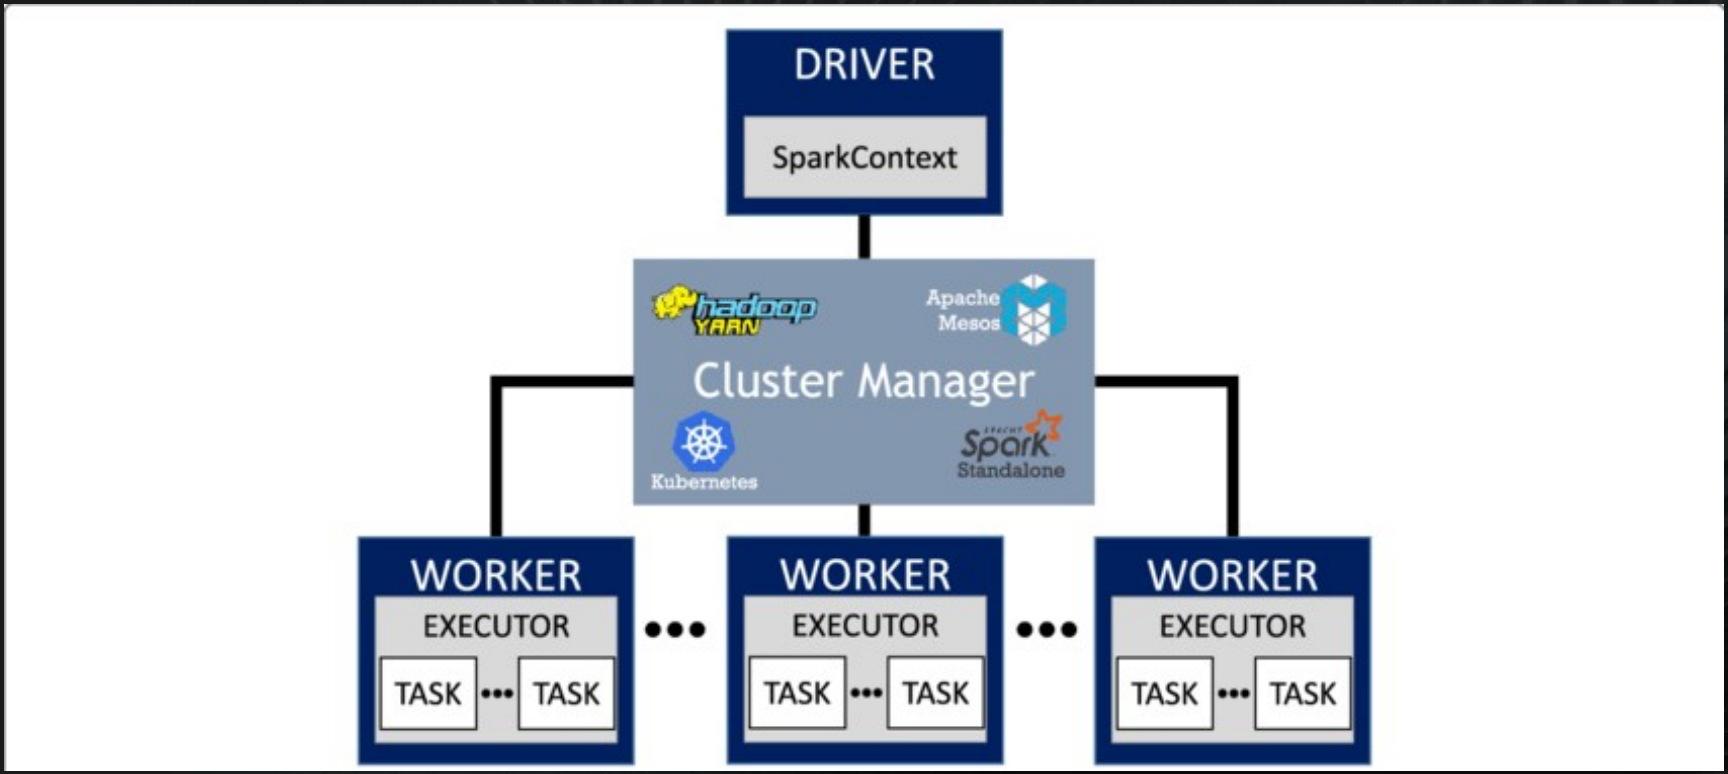

Fonte: ResearchGate.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Databricks: O Lar do Spark

Do Cluster Manual ao Serverless

- Criado pelos fundadores originais do Spark.
- **Zero Setup:** Notebooks prontos para rodar IA em segundos.
- **Serverless Warehouse:** Não precisamos configurar CPUs, apenas usar.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Conceito de Partições

Como dividir uma pizza de 1 Terabyte?

- O Spark divide o arquivo gigante em pequenas "Partições".
- Cada Worker processa uma ou mais partições simultaneamente.
- **Particionamento Ideal:** Se tiver 100 CPUs, você quer pelo menos 100 ou 200 partições.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lazy Evaluation (A Preguiça Inteligente)

Por que o Spark não faz nada de imediato?

- **Transformações (select, filter):** O Spark apenas “anota”.
- **Ações (count, show, save):** O Spark lê o caderninho e executa tudo de uma vez.
- **Vantagem:** O Spark otimiza o caminho (Ex: Filtrar dados antes de carregar na memória).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O DAG (Directed Acyclic Graph)

O Mapa da Mina do Spark

- O Spark desenha um gráfico de dependências antes de agir.
- Ele sabe que se o passo C falhar, ele pode recomeçar do passo B.
- **Linhagem (Lineage):** A garantia de que o dado nunca será perdido.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 02a – O Motor do Big Data

Missão: Ingestão e ETL de Transações CAIXA

- **Cenário:** Processar 1 Milhão de transações sintéticas.
- **Desafio:** Realizar limpeza e filtragem usando PySpark.
- **Ambiente:** Databricks Free Edition.
- **Meta:** Criar uma View Temporária e consultar dados via SQL.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Shuffling: O Inimigo nº 1

Quando os dados precisam mudar de casa

- Ocorre em operações como `groupBy` ou `join`.
- Os Workers precisam trocar dados entre si via **Rede**.
- **Como vimos na Aula 01:** Rede = Latência = Morte da Performance.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

IA Distribuída com Spark MLlib

Treinando Modelos que não cabem na RAM

- O Scikit-Learn sofre em escala; o MLlib prospera.
- **Treinamento Iterativo:** O Spark distribui as matrizes de pesos entre os nós.
- **Pipeline:** Feature Engineering e Modelo em um único fluxo.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 02b – IA em Escala (Fraude)

Missão: Predição de Risco de Fraude PIX

- **Cenário:** Dataset de 1 Milhão de transações.
- **Desafio:** Implementar um Pipeline de Logistic Regression.
- **Ambiente:** Databricks Free Edition.
- **Meta:** Medir a Acurácia e o impacto do Random Forest.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

MLOps: O Próximo Nível (Serving)

Do Spark para a API de Baixa Latência

- Spark é lento para predições pequenas (Overhead).
- **Exportação:** Salvar o modelo em formato **ONNX** ou **MLeap**.
- **Serving:** Rodar a predição em um microsserviço leve (FastAPI) no AKS da CAIXA.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo e Lições do Dia

Dominando o Gigante Spark

- [ ] Entendi por que RAM é melhor que Disco para Big Data.
- [ ] Diferenciei Transformações de Ações.
- [ ] Ingeri e limpei 1 milhão de linhas em segundos.
- [ ] Treinei um modelo de ML que escala horizontalmente.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 03

Cloud Computing & Azure para IA

- Saindo do "Free" para o Cluster Real.
- Provisionamento de Clusters Azure (AKS e Databricks).
- **Desafio:** Como pagar a conta? Otimização de custos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS