Imersão em IA

IA na Nuvem: Escala e Resiliência

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **The Cloud Shift:** IaaS vs. PaaS.
- **Elasticidade:** O fim do desperdício com Scale-to-Zero.
- **Governança:** Azure ML Workspaces e Resource Groups.
- **Lab 03a:** Provisionamento da 'Máquina Infinita'.
- **Orquestração:** O caos dos containers e o Deep Dive no AKS.
- **Resiliência:** HPA (O Pulso da Demanda Real).
- **Lab 03b:** Guerra de Acessos e Auto-scaling ao vivo.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Fim do Baremetal (Hardware Fixo)

De Donos de Máquinas a Arquitetos de Fluxos

- **Tradicional:** Demora comprar e instalar um servidor físico.
- **Hardware Fixo:** Custo fixo 24/7, mesmo o servidor ocioso.
- **Cloud:** Hardware transformado em API (Deploy rápido).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

CAPEX vs. OPEX

Investimento vs. Custo Operacional

- **CAPEX:** Investimento em ativos físicos (Comprar o prédio).
- **OPEX:** Aluguel de capacidade conforme o uso (Pagar o condomínio).
- **Impacto:** Agilidade total para pivotar ou cancelar projetos de IA sem perda de ativos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

IaaS vs. PaaS

Onde você quer gastar seu tempo?

- **IaaS (VMs):** Você gerencia o SO, Antivírus e Patches.
- **PaaS (Azure ML):** Você foca apenas no Modelo e nos Dados.

  A Azure cuida da máquina.
- **Dica:** Automatize tudo o que não melhora a acurácia do seu

  modelo.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

IaaS vs. PaaS

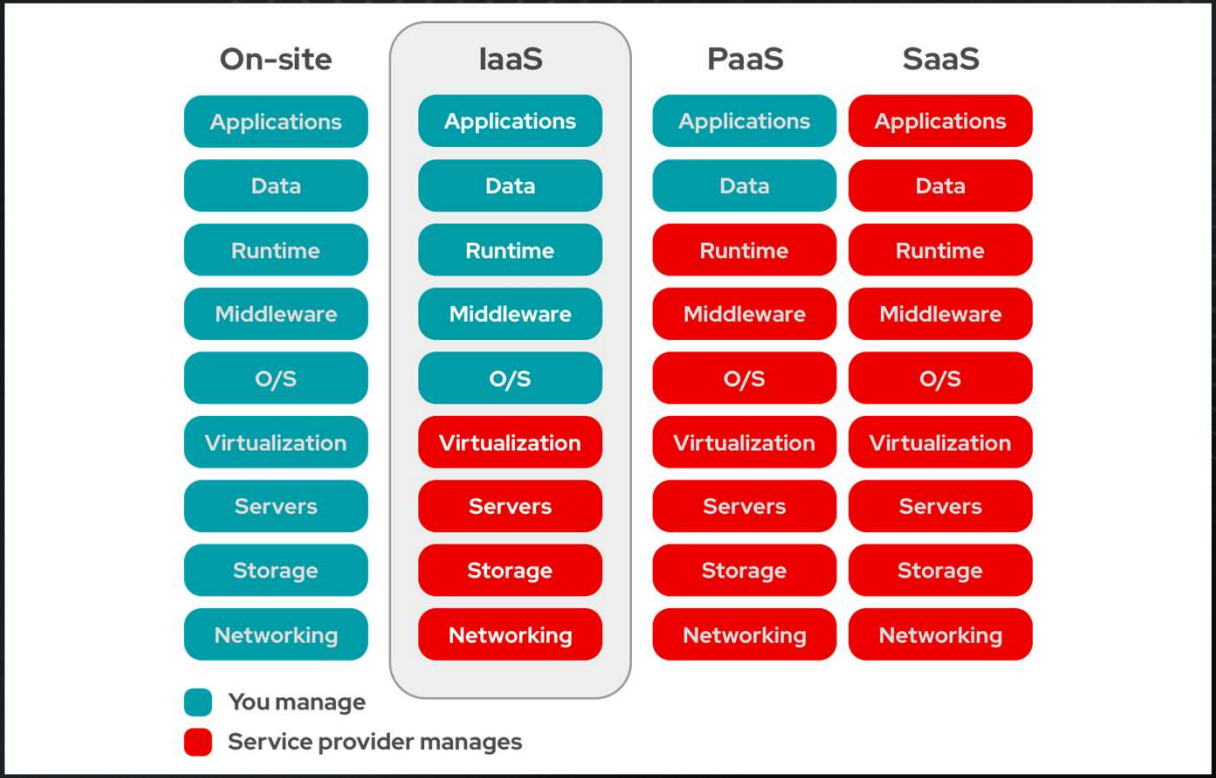

Fonte: Red Hat.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ecossistema Azure ML (AML)

O Centro de Comando da IA

- **Resource Group:** O 'cercadinho' de custos e permissões.
- **Workspace:** Onde o time colabora (Notebooks e Modelos).
- **Key Vault:** O cofre para senhas e segredos bancários.
- **Storage (Blob):** O lago de dados escalável da CAIXA.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Computação no Azure ML

Compute Instance vs. Compute Cluster

- **Instance:** Seu notebook individual na nuvem (Dev).
- **Cluster**: Seu exército (Processamento Pesado).
- **Escala Horizontal:** Adicionar mais máquinas ao exército.
- **Escala Vertical:** Usar máquinas mais potentes (GPUs).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Scale-to-Zero (Economia Real)

O Fim do Desperdício de Dinheiro

- Cluster ligado apenas enquanto há trabalho na fila.
- **Automação:** O job acabou? A Azure desliga as máquinas sozinha.
- **Pagamento:** Cobrança apenas pelos minutos de atividade real.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 03a – A Máquina Infinita

Missão: Provisionamento Elástico para o Feirão

- **Cenário:** Treinar modelo de vendas de imóveis.
- **Desafio:** Criar um cluster que escala de 0 a 4 nós auto.
- **Meta:** Validar o scaling das VMs sob carga e o desligamento automático.
- **Ambiente:** Azure Machine Learning Studio.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Por que Orquestrar Containers?

Do Docker Unitário à Frota de APIs

- 1 API em Docker é fácil; cuidar 1.000 em produção é o caos.
- **Self-healing:** Reiniciar automaticamente apps que travaram.
- **Service Discovery:** Como um microserviço é encontrado?
- **Load Balancing:** Distribuir o tráfego de forma justa.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

AKS: O Maestro da Escala

Azure Kubernetes Service

- **Control Plane:** O cérebro vigilante (Gerenciado pela Azure).
- **Nodes:** Onde a IA realmente 'mora' e processa.
- **Abstração:** Você entrega o container, o AKS entrega a alta disponibilidade.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Pods: Os Apartamentos da IA

A Menor Unidade do Kubernetes

- Containers nunca rodam 'soltos'; rodam dentro de **Pods**.
- **Efemeridade:** Pods podem morrer e surgir em outros nós.
- **ReplicaSet:** Garante que o número de cópias desejado esteja sempre ativo.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Pulso da Demanda (HPA)

Horizontal Pod Autoscaler

- **Funcionamento:**
  - **Métricas:** O Kubernetes lê o uso de CPU/Memória em tempo real.
  - **Gatilho:** Passou de 50% de uso? Crie novas réplicas instantaneamente.
  - **Analogia:** Abrir novos guichês na agência conforme a fila cresce.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resiliência > Perfeição

Sobrevivendo a Falhas de Infraestrutura

- O que acontece se um servidor físico da Azure falhar?
- O AKS detecta a queda e move os Pods para nós saudáveis.
- **Resultado:** O app da CAIXA continua online para o cidadão.
- **Conceito:** Falhas são inevitáveis em Sistemas distribuídos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 03b – O Pulso da Demanda

Missão: Auto-scaling no Dia do Bolsa Família

- **Cenário:** Simular pico de 10x acessos na API de biometria.
- **Desafio:** Configurar o HPA e o sistema recebe uma carga.
- **Meta:** Ver o Kubernetes criando Pods 'ao vivo'.
- **Ambiente:** Killercoda (Kubernetes Playground).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo e Lições do Dia

Dominando a Nuvem Elástica

- [ ] Entendi a avaliação de compra de hardware fixo para IA.
- [ ] Provisionei um cluster elástico com Scale-to-Zero.
- [ ] Compreendi o papel do Kubernetes (K8s) na produção.
- [ ] Vi o sistema 'respirar' sozinho sob carga massiva.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 04

Otimização e Performance (The Slim Model)

- Como fazer o modelo caber em hardware barato e limitado.
- Quantização, Pruning e Batching Dinâmico.
- **Foco:** Redução extrema de latência e custo de inferência.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS