Imersão em IA

Otimização e Performance em Larga Escala

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **O Inimigo:** O Gargalo de Von Neumann.
- **Quantização:** PTQ, QAT e o segredo do NF4.
- **Lab 04a:** O Peso da Precisão (LLM Turbo).
- **Pruning:** Estruturado vs. Não Estruturado.
- **KV Cache:** Otimização de memória para Chatbots.
- **Batching:** Do estático ao Continuous Batching.
- **Lab 04b:** A Poda Inteligente e o Efeito Lote.
- **Performance:** Métricas de Latência vs. Throughput.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Inimigo: Gargalo de Von Neumann

Por que a Memória é o Problema?

- **Processamento:** GPUs são incrivelmente rápidas.
- **Transferência:** O dado leva tempo entre VRAM e a GPU.
- **Memory Bound:** A IA gasta mais tempo "esperando o dado" do que calculando.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Inimigo: Gargalo de Von Neumann

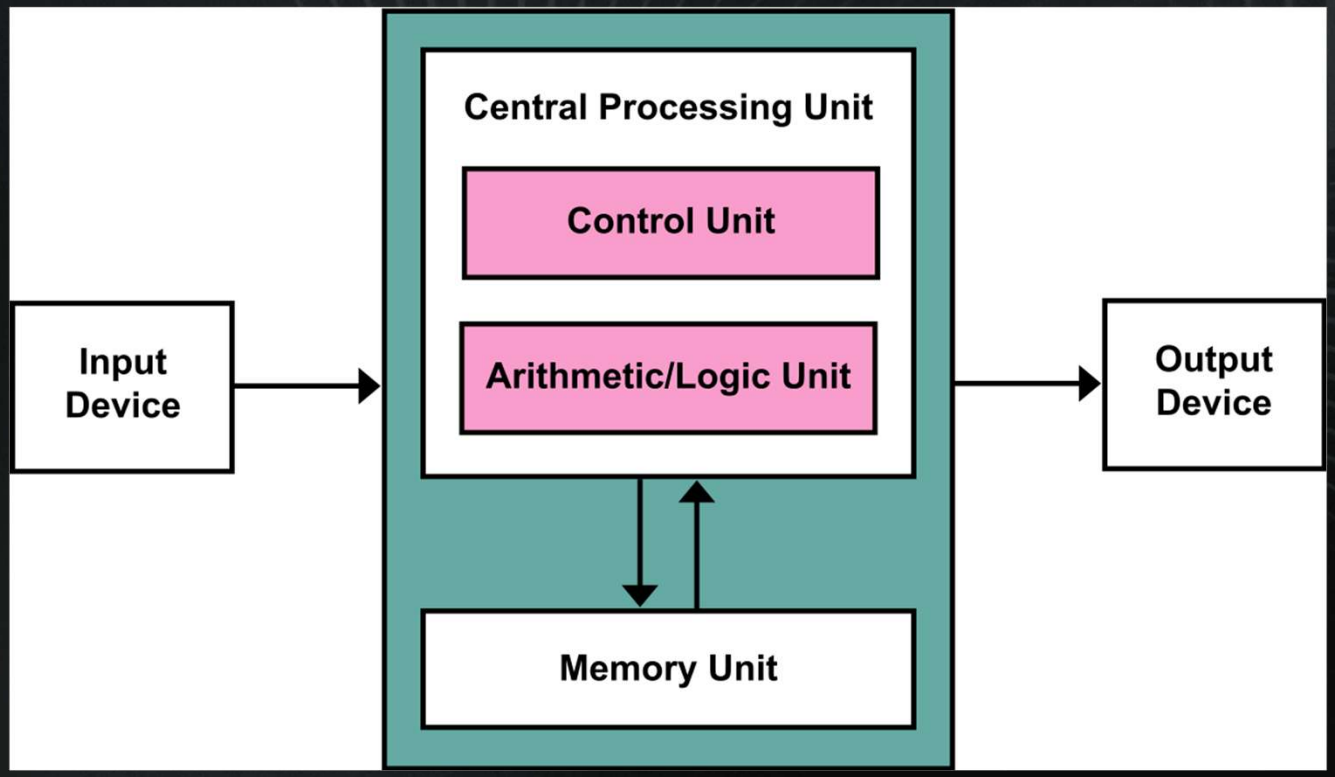

Fonte: StackOverflow - O que é o gargalo de von Neumann?.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Problema da "Obesidade" em IA

O Custo Proibitivo do Modelo Padrão

- **Modelo 7B (FP32):** 28GB de VRAM (Exige GPU de R$ 50k+).
- **Modelo 7B (INT4):** 4GB de VRAM (Cabe em um computador comum).
- **Impacto:** Redução de 85% na infraestrutura necessária.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Quantização: A Dieta dos Números

Reduzindo a Precisão, Ganhando Velocidade

- **FP32 (Original):** 32 bits por peso (Alta fidelidade).
- **INT8 / INT4:** 8 ou 4 bits por peso (Baixa fidelidade).
- **Trade-off:** Perda mínima de acurácia por um ganho massivo de espaço.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

PTQ vs. QAT

Quando e Como Quantizar?

- **Técnicas:**
  - **PTQ (Post-Training):** Quantiza o modelo pronto. (Rápido e fácil).
  - **QAT (Training-Aware):** Treina o modelo já "sabendo" que será 4-bit.
- **Qualidade:** O QAT recupera quase 100% da perda de inteligência.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

NF4: O Estado da Arte

NormalFloat 4 (O Segredo do QLoRA)

- **Por que NF4?**
  - Pesos de IA seguem uma distribuição normal (curva de sino).
  - O NF4 foca a precisão onde os pesos são mais frequentes.
  - **Resultado:** INT4 com inteligência de FP16.
- **Standard:** A biblioteca **bitsandbytes** faz isso para o dia a dia.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 04a – O Peso da Precisão

Missão: LLM Turbo no Hardware Comum

- **Cenário:** Rodar o TinyLlama (1.1B) na GPU gratuita do Colab.
- **Desafio:** Comparar o modelo original vs. a versão 4-bit.
- **Métrica:** Tokens por segundo e consumo de VRAM (MB).
- **Insight:** Ver o sistema gerar texto 3x mais rápido apenas reduzindo a precisão.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Pruning: Cortando o Peso Morto

Poda de Neurônios e Conexões

- **Funcionamento:**
  - Muitos pesos em uma rede neural são "quase zero".
  - **O Corte:** Zerar os menores pesos e manter apenas os importantes.
- **Objetivo:** Reduzir o número de operações (FLOPs).
- **Analogia:** Podar uma árvore para que ela cresça melhor.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Pruning: Cortando o Peso Morto

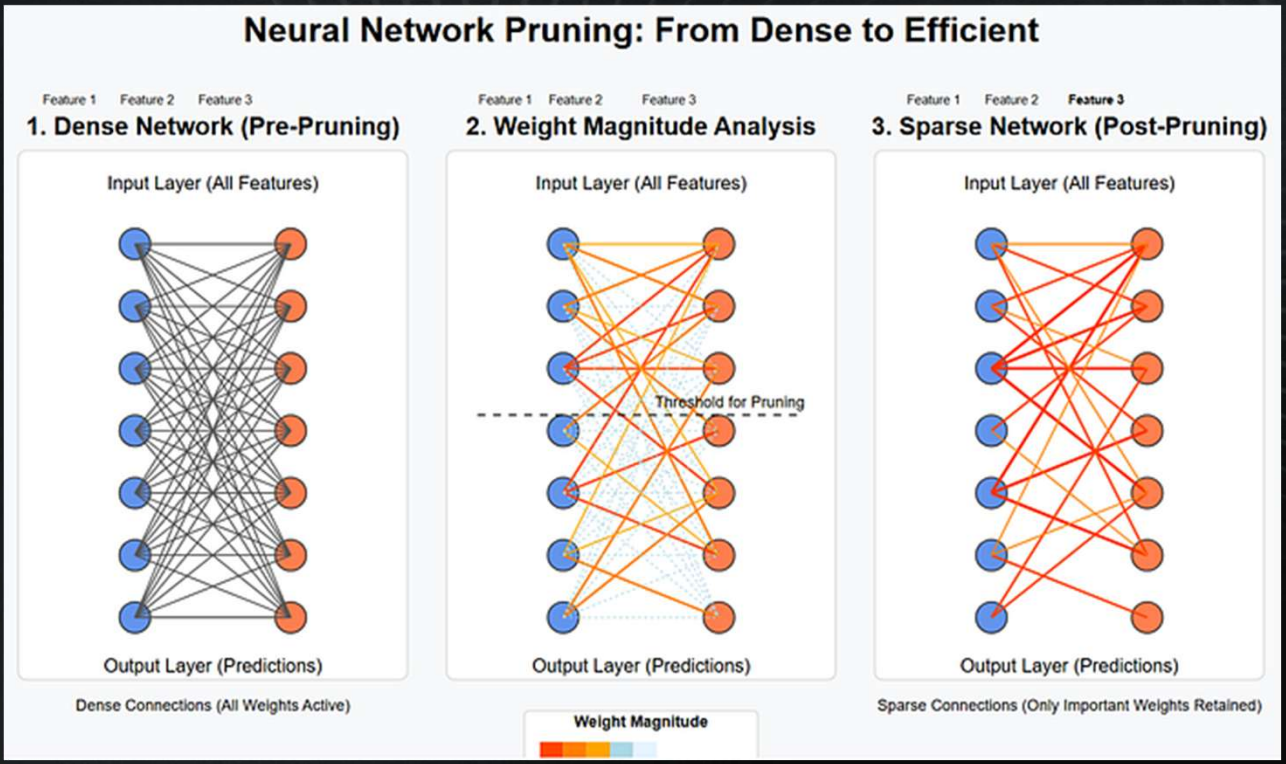

Fonte: Medium - Optimizing Large Language Models.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Pruning Estruturado vs. Não Estruturado

Como Cortar sem Perder a Forma?

- **Tipos:**
  - **Não Estruturado:** Corta pesos aleatórios. (Boa compressão).
  - **Estruturado:** Corta neurônios ou canais inteiros. (Boa velocidade).
- **Desafio:** O hardware moderno (GPUs) prefere matrizes cheias (Estruturado).

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

KV Cache: O Ouro das LLMs

Otimizando a Memória do Contexto

- **Problema:** LLMs precisam lembrar do contexto a cada token.
- **Solução:** Salvar as chaves e valores em um cache.
- **Custo:** O KV Cache cresce com o tamanho da conversa.
- **Otimização:** Técnicas como **Grouped Query Attention (GQA)** reduzem esse cache.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Batching: O Segredo do Throughput

Do Processamento Solitário ao Loteamento

- **Problema:** GPU para uma frase é desperdício de energia.
- **Vazão (Throughput):** 64 frases juntas leva o mesmo tempo.
- **Batch Size:** O número que define a eficiência do servidor.
- **Cenário:** Servidores de inferência da CAIXA processando mil chats.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Continuous Batching (vLLM)

Evolução: Batching sem Espera

- **Estático:** Espera 10 pessoas para sair a van. (Tem latência).
- **Contínuo:** Passageiros entram na van enquanto ela anda.
- **Benefício:** Otimiza uso da GPU sem aumentar a latência.
- **Ferramentas:** vLLM e Triton Inference Server.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 04b – A Poda e o Efeito Lote

Missão: Visão Computacional de Alta Vazão

- **Cenário:** Processar fotos de documentos para o app CAIXA.
- **Atividades:**
  - [ ] Aplicar **Pruning** em uma ResNet-18 para reduzir tamanho.
  - [ ] Comparar **Batch Size 1** vs. **Batch Size 64**.
- **Meta:** Provar que o processamento em lote é 10x eficiente.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Métricas de Performance (KPIs)

Latência vs. Throughput (Vazão)

- **Latência (TTFT):** Tempo para o primeiro token aparecer.
- **Throughput (RPS):** Quantas requisições por segundo.
- **P99:** O tempo que 99% dos usuários .
- **Balanceamento:** Ser rápido sem gastar milhões em GPUs.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Trade-off: O Equilíbrio da IA

Inteligência vs. Velocidade

- **Regra:** Toda otimização tem um custo.
- **Perda:** Acurácia pode cair em modelos muito podados.
- **Decisão:** “Um 100% que leva 10s, ou um 95% que leva 0.1s?"
- **Resposta:** Depende da aplicação.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo e Lições do Dia

Engenharia de Performance para o Mundo Real

- [ ] Entendi o impacto da precisão numérica no custo.
- [ ] Diferenciei Quantização de Poda (Pruning).
- [ ] Compreendi como o Batching maximiza o uso da GPU.
- [ ] Vi o poder das LLMs “podadas" rodando localmente.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Preview da Aula 05

O Futuro Distribuído (Edge e Federated)

- **Edge Computing:** IA rodando dentro do celular do cliente.
- **Federated Learning:** Treinar sem ver os dados do usuário.
- **Privacidade:** IA soberana e segura no ecossistema bancário.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS