Imersão em IA

Arquiteturas Modernas, Edge e Federated Learning

alura + FIAP
PARA EMPRESAS

Prof. MSc. Rafael Matsuyama

Agenda

- **O Dilema:** Centralização vs. Latência e Privacidade.
- **Edge Computing:** IA na Borda (Celulares e Agências).
- **Lab 05a:** IA na Ponta (ONNX e TFLite).
- **Federated Learning:** Treinamento sem Compartilhamento.
- **Privacidade:** LGPD e o Modelo Soberano.
- **Agregadores:** FedAvg e o Segredo Coletivo.
- **Lab 05b:** O Treinamento Federado (Flower).
- **Conclusão:** O Futuro do Ecossistema Bancário.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Dilema da Centralização

Por que a Nuvem Sozinha Não Basta?

- **Latência:** Milissegundos custam caro em transações.
- **Banda:** Transferir Terabytes de dados é lento e custoso.
- **Privacidade:** Dados sensíveis da CAIXA não podem "vazar" para a nuvem pública.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Edge Computing (IA na Borda)

Trazendo a Inteligência para a Origem

- **Definição:** Processar o dado no dispositivo que o gerou.
- **Exemplos:** Câmeras de segurança, ATMs, Smartphones.
- **Vantagem:** Resposta instantânea e operação offline.
- **Cenário CAIXA:** Validação biométrica local no app CAIXA.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ciclo de Vida do Edge AI

Como Chegar à Borda?

- **Treinamento:** Feito na Nuvem/HPC (Onde há poder infinito).
- **Compressão:** Quantização e Poda (Visto na Aula 04).
- **Conversão:** Formatos leves como ONNX e TFLite.
- **Deploy:** Distribuição para milhares de dispositivos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Motores de Execução na Borda

ONNX e TFLite: Os Idiomas da Borda

- **TFLite:** Otimizado para ecossistemas mobile (Android/iOS).
- **ONNX:** Formato universal (Interoperabilidade total).
- **Vantagem:** Rodam sem Python ou bibliotecas pesadas.
- **Performance:** Aceleração via NPU (Neural Processing Unit) dos chips modernos.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 05a – IA na Ponta

Missão: O Modelo que Cabe no Bolso

- **Cenário:** Converter um modelo de 50MB para 4MB.
- **Atividades:**
  - [ ] Exportar MobileNetV2 para SavedModel.
  - [ ] Converter para TFLite e ONNX.
  - [ ] Medir o ganho de velocidade (Throughput) na inferência local.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Grande Problema da LGPD

O Paradoxo do Treinamento Centralizado

- **Dilema:**
  - Precisamos de muitos dados para treinar modelos de fraude.
  - A lei (LGPD) e o sigilo bancário proíbem centralizar dados sensíveis.
  - **Risco:** Manter os dados isolados cria "Silos de Inteligência".
- **Insight:** Como aprender com o todo sem expor a parte?

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Federated Learning (Aprendizado Federado)

O Conhecimento Sem a Exposição

- **Conceito:** O modelo roda local, o dado nunca sai da agência.
- **O Processo:**
  - O servidor envia um "modelo mestre" para as agências.
  - Cada agência treina com seus dados locais (Privados).
  - Apenas os **pesos (gradientes)** são enviados de volta.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Algoritmo FedAvg

Federated Averaging: A Agregação

- **Funcionamento:**
  - O servidor recebe os ajustes de 1000 "nós".
  - Realiza uma média aritmética (ou ponderada) desses ajustes.
  - Atualiza o modelo global com o "conhecimento médio" de todos.
- **Eficiência:** O modelo global se torna resiliente a variações.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Média Ponderada: A Voz da Experiência

Por que Nem Todo Nó Tem o Mesmo Peso?

- **Lógica:**
  - Agência com 10 mil clientes deve influenciar mais que uma com mil.
  - **Fórmula:** Peso da atualização é proporcional ao volume de dados local.
- **Cenário:** Ajustar o modelo de risco de crédito com base na representatividade das regiões.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Ataques de Envenenamento (Poisoning)

O Lado Obscuro: Quando um Nó Mente

- **Risco:** Um dispositivo hackeado envia pesos errados.
- **Impacto:** Envenenar o modelo para que não detecte fraudes.
- **Defesa: Robust Aggregation** (Ignorar atualizações ruins).
- **Insight:** Federated Learning exige confiança técnica, não apenas contratual.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Lab 05b – O Segredo Compartilhado

Missão: Treinando em Silo com o Flower

- **Cenário:** 3 agências treinando um modelo de Fraude.
- **Atividades:**
  - [ ] Criar 3 Dataloaders independentes (Silos).
  - [ ] Treinar 3 modelos locais via PyTorch.
  - [ ] Implementar o FedAvg manual para atualizar o modelo global.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Diferential Privacy (Privacidade Diferencial)

Camadas Extras de Segurança

- **Cenário:** Processar fotos de documentos para o app CAIXA.
- **Atividades:**
  - [ ] Aplicar **Pruning** em uma ResNet-18 para reduzir tamanho.
  - [ ] Comparar **Batch Size 1** vs. **Batch Size 64**.
- **Meta:** Provar que o processamento em lote é 10x eficiente.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Criptografia Homomórfica

Computando sobre o Invisível

- **Conceito:** Somar ou multiplicar números criptografados.
- **Aplicação:** O servidor faz cálculos sem descriptografar.
- **Vantagem:** Segurança matemática total.
- **Desafio:** Custo computacional ainda é muito alto.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

O Ecossistema Bancário do Futuro

A CAIXA como uma Rede Neural Distribuída

- **Visão:**
  - Cada ATM é um nó sensor.
  - Cada celular é um nó de treinamento.
  - A Nuvem é o agregador soberano.
- **Resultado:** IA que respeita o sigilo do cidadão.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

Resumo da Semana 10

De Spark à Soberania de Dados

- [ ] Fundamentos de Escala e Latência.
- [ ] Ecossistema Spark e Databricks.
- [ ] Orquestração em Cloud e Kubernetes.
- [ ] Otimização e Performance (Quantização).
- [ ] Edge Computing e Federated Learning.

Copyright © 2026 - Prof. Rafael Matsuyama (profrafael.matsuyama@fiap.com.br)

“Não importa o quão devagar você vá, desde que não pare.”

Confúcio

Filósofo Chinês

Rafael Matsuyama

Professor de MBA

profrafael.matsuyama@fiap.com.br

https://linkedin.com/in/rafaelmatsuyama

Podemos contar com **o seu feedback?**

Escaneie o QR Code ao lado e responda a nossa **Pesquisa de Avaliação** sobre esta aula.

alura + FIAP

PARA EMPRESAS